한빛아카데미 Hanbit Academy, Inc.

10/14 수업까지 시험

COMPUTER VISION 컴퓨터 비전

기본 개념부터 최신 모바일 응용 예까지

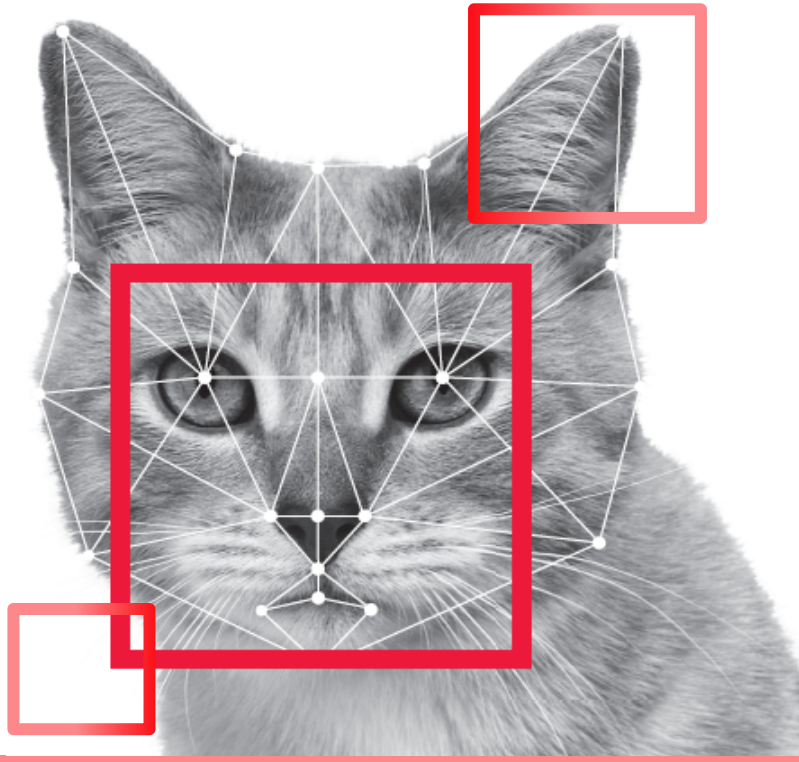

4장. 지역 특징 검출

PREVIEW

대응점 찾기

- 같은 장면을 다른 시점에서 찍은 두 영상에서 대응하는 점의 쌍을 찾는 문제
- 파노라마, 물체 인식/추적, 스테레오 등 컴퓨터 비전의 중요한 문제 해결의 단초

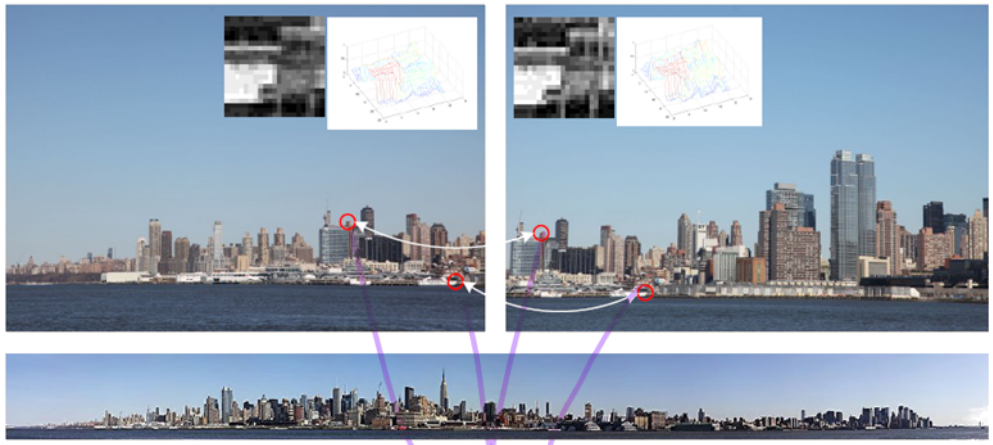

그림 4-1 대응점 찾기(확대 영상은 배의 꽁무니 부근)

feature Vector
(→ 기술자 (descriptor))

- 세 단계로 해결

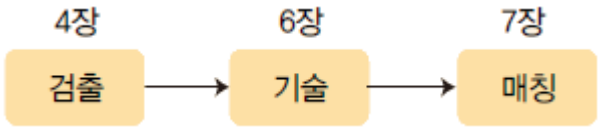

매칭

명암값이 상하좌우 차이 많이 나야 구별 가능

flat : 명암 차이 X

edge : 상하 or 좌우로만 명암 차이

corner : 상하좌우 명암 차이

각 절에서 다루는 내용

1. 지역 특징 검출의 기초

2. 이동과 회전에 불변한 특징점 검출

3. 위치 찾기 알고리즘

4. 스케일에 불변한 특징점 검출

4.1 지역 특징 검출의 기초

4.1.1 특징 검출의 역사: 지역 특징의 대두

4.1.2 지역 특징의 성질

4.1.3 지역 특징 검출 원리

4.1.1 특징 검출의 역사: 지역 특징의 대두

- 무엇을 특징점으로 쓸 것인가?
  - 에지?
    - 에지 강도와 방향 정보만 가지므로, 매칭에 참여하기에 턱없이 부족

- 다른 곳과 두드러지게 달라 풍부한 정보 추출 가능한 곳
  - 에지 토막에서 곡률이 큰 지점을 코너로 검출
    - 코너 검출, dominant point 검출 등의 주제로 80년대 왕성한 연구
    - 90년대 소강 국면, 2000년대 사라짐
    - 더 좋은 대안이 떠올랐기 때문
  - 지역 특징이라는 새로운 물줄기
    - 명암 영상에서 직접 검출
    - 의식 전환: 코너의 물리적 의미 → 반복성

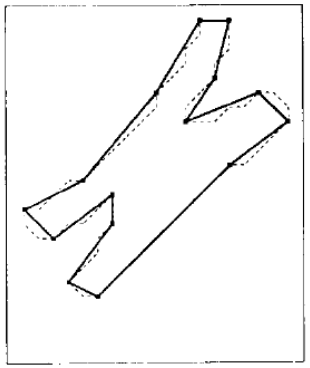

4.1.2 지역 특징의 성질

지역 특징

- <위치,스케일,방향,특징 벡터>=((y,x),$s,\theta,\mathbf{x}$)로 표현
  - 검출 단계 (4장): 위치와 스케일 알아냄
  - 기술 단계 (6장): 방향과 특징 벡터 알아냄

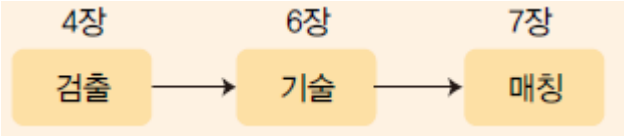

지역 특징이 만족해야 할 특성

- 반복성
- 분별력
- 지역성 그 지역을 대표하는 값
- 정확성
- 적당한 양
- 계산 효율

이들 특성은 길항 관계

- 응용에 따라 적절한 특징을 선택해야 함

4.1.3 지역 특징 검출 원리

- 원리
  - 인지 실험
    - 대응점을 찾기가 쉬운(좋은) 점은? → 사람에게 쉬운 곳이 컴퓨터에게도 쉽다.
  - 좋은 정도를 어떻게 수량화할까?

    → 여러 방향으로 밝기 변화가 나타나는 곳일수록 높은 점수

    ↳ Corner

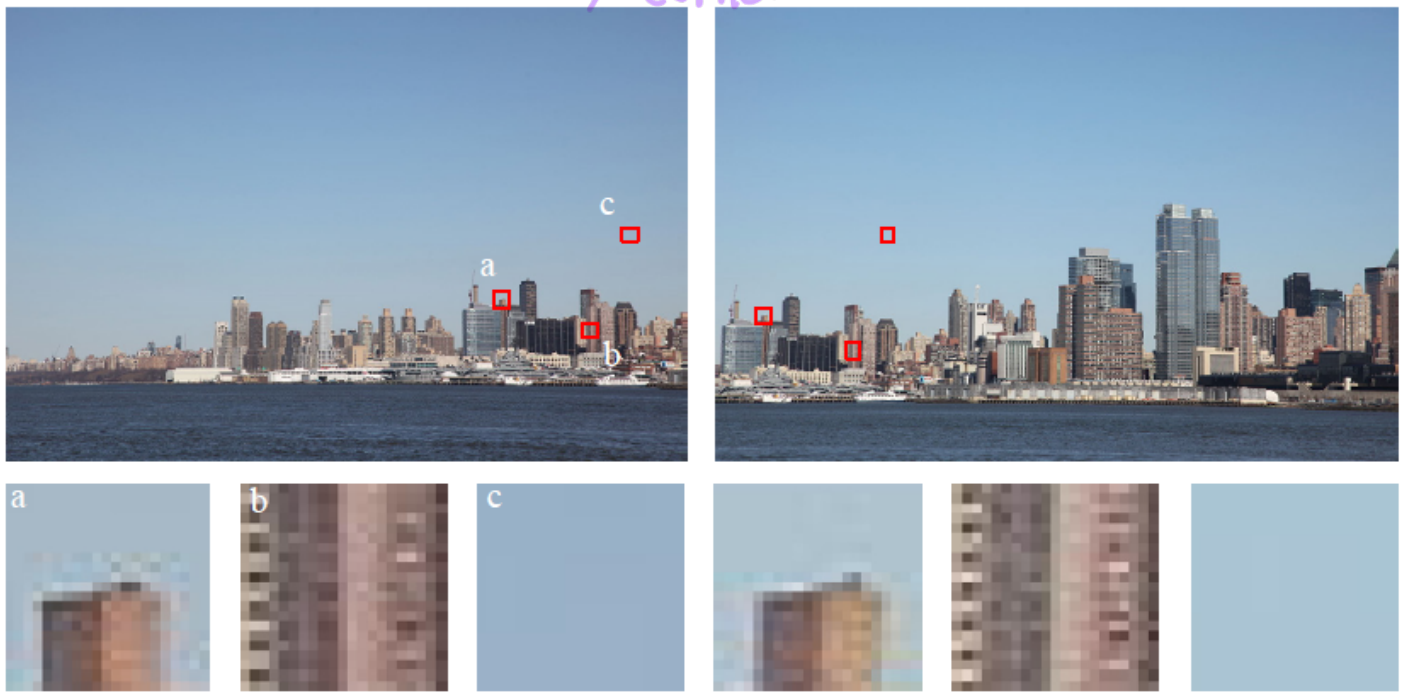

그림 4-2 a, b, c 중에 어느 곳이 지역 특징으로 유리할까?

Corner Detection: Basic Idea

- We should easily recognize the point by looking through a small window
- Shifting a window in *any direction* should give *a l arge change* in intensity

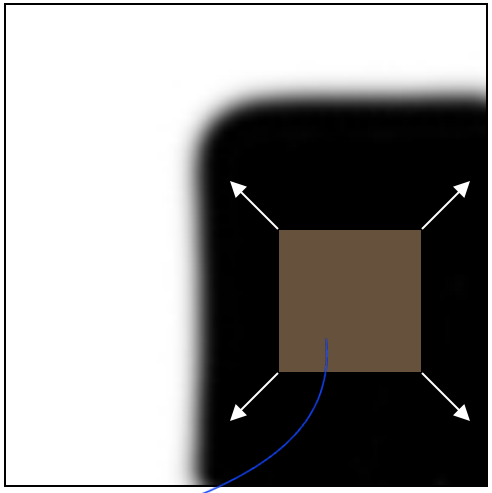

"flat" region:
no change in all directions

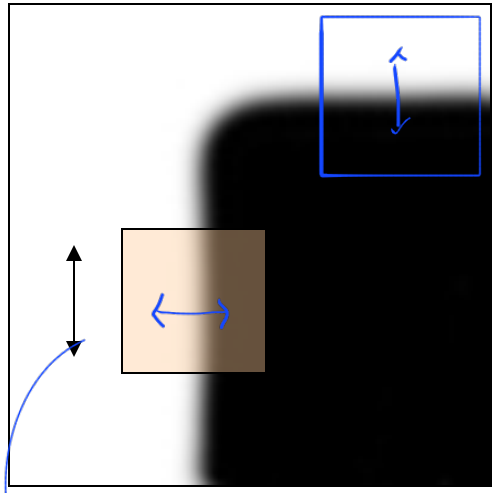

"edge":
no change alon g the edge direc tion

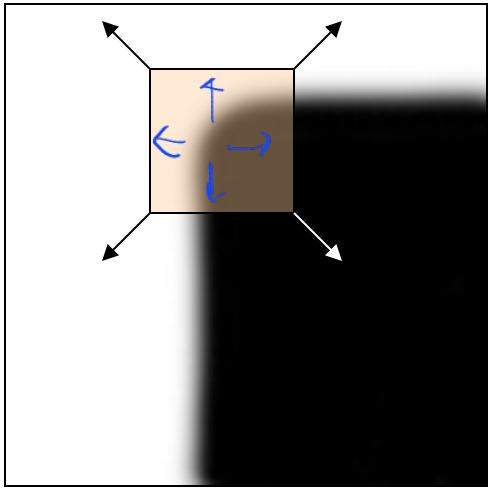

"corner":
significant chan ge in all directio ns

Source: A. Efros

4.2 이동과 회전에 불변한 특징점 검출

- 앞 절에서 특징이 '무엇'인지 공부하였다.
- 이제 '어떻게' 찾을 것인지 공부해보자.

4.2.1 모라벡 알고리즘

4.2.2 해리스 코너

4.2.3 2차 미분을 사용한 방법

4.2.4 슈산

4.2.1 모라벡 알고리즘

- 인지 실험에 주목한 모라벡 [Moravec80]
  - 제곱차의 합으로 밝기 변화 측정

$$S(v,u)=\sum_{y=-1}^{1}\sum_{x=-1}^{1}w(y,x)(f(y+v,x+u)-f(y,x))^2 \quad (4.1)$$

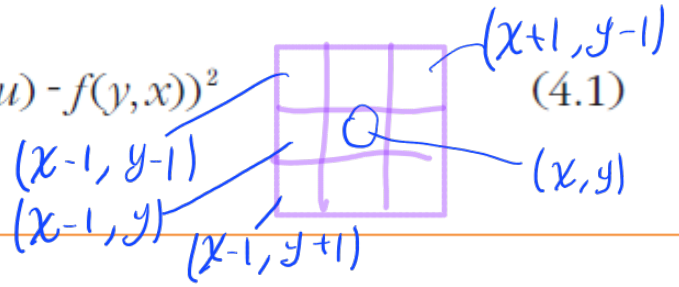

8-연결성

예제 4-1 **제곱차 합 계산**

[그림 4-3]은 삼각형을 가진 12×12 영상이다. 현재 조사하고 있는 점은 (5, 3)에 위치한 b이고, 마스크는 모든 값이 1인 3×3 크기의 박스형이라 하자. 이때 오른쪽으로 한 화소만큼 이동시킨 $S(0,1)$을 계산해 보면 다음과 같이 4라는 값을 얻는다.

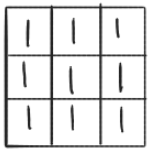

$$S(0,1)=\sum_{y}\sum_{x}w(y,x)(f(y,x+1)-f(y,x))^2, \text{ 이때 } w(y,x)=\begin{cases}1, & 4\le y\le 6,\ 2\le x\le 4\\ 0, & \text{그 외}\end{cases}$$

$$=\sum_{4\le y\le 6}\sum_{2\le x\le 4}(f(y,x+1)-f(y,x))^2=4$$

v \ u	-1	0	1
-1	3	1	6
0	3	0	4
1	3	0	3

같은 방식으로 나머지 v와 u 값에 대해 $S(v,u)$를 계산해 보면, 왼쪽과 같은 $S(v,u)$ 맵을 완성할 수 있다. 점 b를 기준으로 생성한 맵으로, 연필을 들고 다른 점에 대해서도 계산해 보기 바란다. 손으로 직접 해 보는 것의 힘은 생각보다 강하다!

4.2.1 모라벡 알고리즘

	0	1	2	3	4	5	6	7	8	9	10	11
0	0	0	0	0	0	0	0	0	0	0	0	0
1	0	0	0	0	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0	c 0	0	0	0
3	0	0	0	1	0	0	0	0	0	0	0	0
4	0	0	0→1→1→			0	0	0	0	0	0	0
5	0	0	0→b 1→1→			1	0	0	0	0	0	0
6	0	0	0→1→1→			1	1	0	0	0	0	0
7	0	0	0	1	1	1	1	a 1	0	0	0	0
8	0	0	0	0	0	0	0	0	0	0	0	0
9	0	0	0	0	0	0	0	0	0	0	0	0
10	0	0	0	0	0	0	0	0	0	0	0	0
11	0	0	0	0	0	0	0	0	0	0	0	0

(a) 합성 영상

$$\frac{1^2+0^2+1^2}{1^2+0^2+0^2}\Big/\frac{1^2+0^2+0^2}{1^2+0^2+0^2} = 4$$

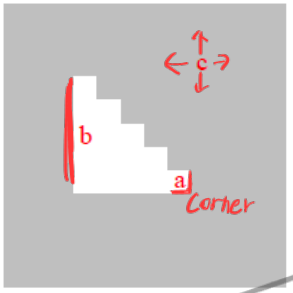

u

v	-1	0	1
-1	3	4	4
0	2	0	2
1	4	3	2

a Corner

최솟값 2

u

v	-1	0	1
-1	3	1	6
0	3	0	4
1	3	0	3

b edge

최솟값 1

오른쪽으로 하나 이동한 화소와의 명암 차이

u

v	-1	0	1
-1	0	0	0
0	0	0	0
1	0	0	0

c flat

최솟값 0

(b) 세 지점에서 $S(v,u)$ 맵

그림 4-3 $S(v,u)$ 맵

← 3*3 마스크로 측정

4.2.1 모라벡 알고리즘

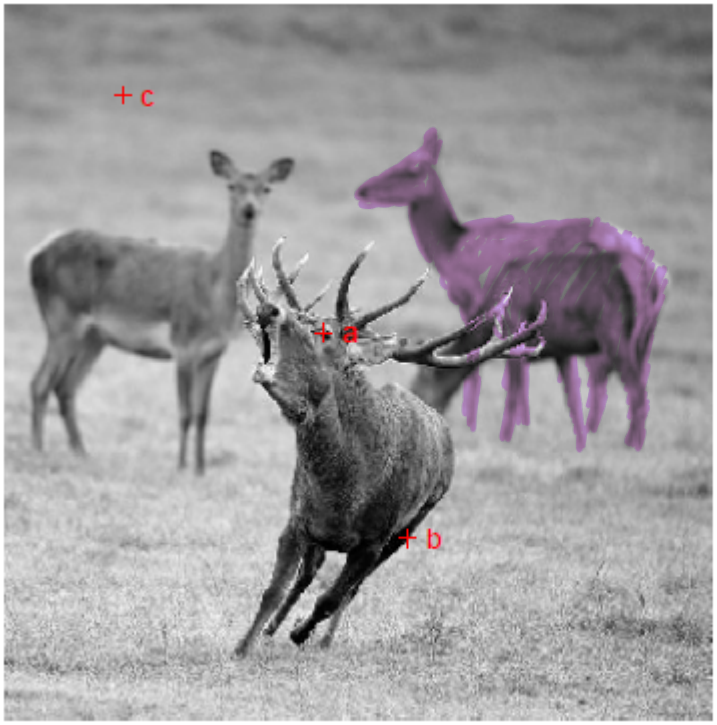

> 원래 영상

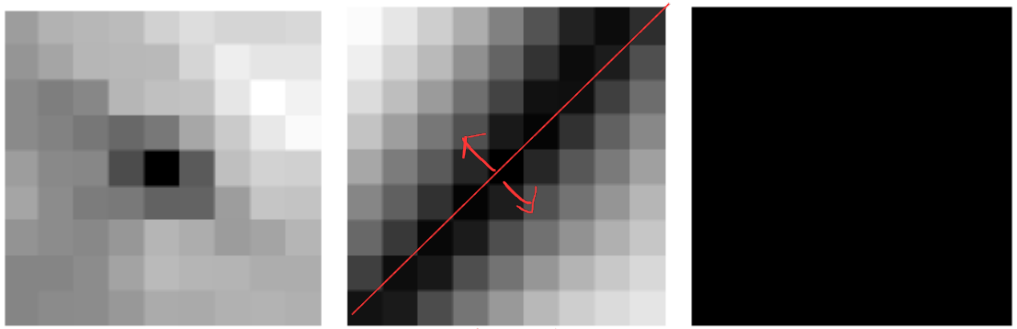

← 9*9 마스크로 측정

> a Corner > b 대각선 Edge > c flat

그림 4-4 실제 영상에서 S 맵(밝을수록 큰 값)

4.2.1 모라벡 알고리즘

- $S(.)$ 맵을 관찰해 보면,
  - a와 같은 코너에서는 모든 방향으로 변화가 심함
  - b와 같은 에지에서는 에지 방향으로 변화 적지만, 에지에 수직 방향으로 변화 심함
  - c와 같은 곳은 모든 방향으로 변화 적음
  - a에 높은 값, c는 아주 낮은 값, b는 그 사이 값을 부여하는 함수를 만들면 됨

- 모라벡의 함수
  - 특징 가능성 값 C

$$C = \min(S(0,1), S(0,-1), S(1,0), S(-1,0)) \qquad (4.2)$$

4-방향성

  - 한계
    - 한 화소만큼 이동하여 네 방향만 봄
    - 잡음에 대한 대처 방안 없음

4.2.2 해리스 코너

- 해리스의 접근 [Harris88]
  - 가중치 제곱차의 합을 이용한 잡음 대처

filter ← noise가 많으면 Gaussian filter 사용

$$S(v,u) = \sum_y \sum_x G(y,x)(f(y+v,x+u) - f(y,x))^2 \qquad (4.3)$$

  - 테일러 확장 $f(y+v,x+u) \cong f(y,x) + vd_y(y,x) + ud_x(y,x)$ 을 대입하면,

$$S(v,u) \cong \sum_y \sum_x G(y,x)(vd_y(y,x) + ud_x(y,x))^2 \qquad (4.5)$$

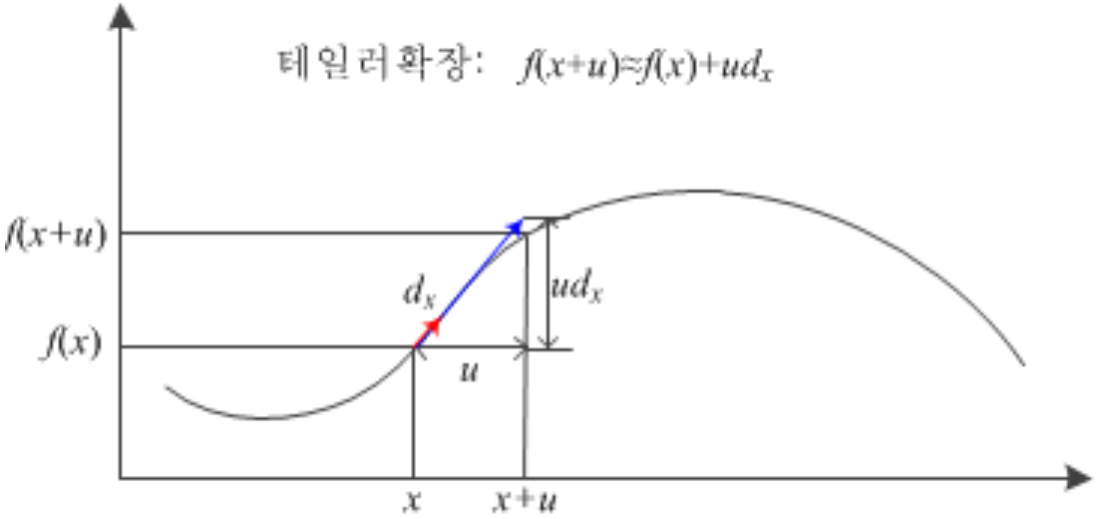

4.2.2 해리스 코너

- 계속 유도하면,

$$
\begin{aligned}
S(v,u) &\cong \sum_y \sum_x G(y,x)(vd_y + ud_x)^2 \\
&= \sum_y \sum_x G(y,x)(v^2 d_y^2 + 2vud_y d_x + u^2 d_x^2) \\
&= \sum_y \sum_x G(y,x)(v\ u) \begin{pmatrix} d_y^2 & d_y d_x \\ d_y d_x & d_x^2 \end{pmatrix} \begin{pmatrix} v \\ u \end{pmatrix} \\
&= (v\ u) \sum_y \sum_x G(y,x) \begin{pmatrix} d_y^2 & d_y d_x \\ d_y d_x & d_x^2 \end{pmatrix} \begin{pmatrix} v \\ u \end{pmatrix}
\end{aligned}
$$

dx^2, dy^2 미분

서로와 관련 X

dx dy

↳ covariance

$$
S(v,u) \cong (v\ u) \begin{pmatrix} \sum_y \sum_x G(y,x) d_y^2 & \sum_y \sum_x G(y,x) d_y d_x \\ \sum_y \sum_x G(y,x) d_y d_x & \sum_y \sum_x G(y,x) d_x^2 \end{pmatrix} \begin{pmatrix} v \\ u \end{pmatrix}
$$

↳ (-) x축↓, y축↓

(+) x축↑, y축↑

dx dy 값을 양상을 알 수 있다

flat인지 edge인지

dx^2, dy^2↑

corner인지 알 수 있다

4.2.2 해리스 코너

- 2차 모멘트 행렬 A

$$S(v,u) \cong (v\ u)\begin{pmatrix} G \circledast d_y^2 & G \circledast d_y d_x \\ G \circledast d_y d_x & G \circledast d_x^2 \end{pmatrix}\begin{pmatrix} v \\ u \end{pmatrix} = \mathbf{u}\mathbf{A}\mathbf{u}^{\mathrm{T}}$$

$$\mathbf{A} = \begin{pmatrix} G \circledast d_y^2 & G \circledast d_y d_x \\ G \circledast d_y d_x & G \circledast d_x^2 \end{pmatrix} \qquad (4.7)$$

  - (v,u)는 실수 가능
  - **A**를 (v,u) 무관하게 계산할 수 있음 ($\because$ S가 **u**와 **A**의 곱으로 인수 분해되어 있으므로)
  - **A**는 영상 구조를 나타냄 → **A**를 잘 분석하면 특징 여부를 판정할 수 있음

flat or Edge or Corner

Corner Detection: Mathematics

- First-order Taylor approximation for small motions $[u, v]$:

$$I(x+u, y+v) = I(x,y) + I_x u + I_y v + \text{higher order terms}$$

$$\approx I(x,y) + I_x u + I_y v$$

$$= I(x,y) + \begin{bmatrix} I_x & I_y \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix}$$

- Let's plug this into

$$E(u,v) = \sum_{(x,y) \in W} [I(x+u, y+v) - I(x,y)]^2$$

If f is a function, then we can approximate $f(x)$ about the point where $x = a$ by the polynomial

$$f(a) + f'(a)(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \cdots + \frac{f^{(n)}(a)}{n!}(x-a)^n + R_n$$

where R_n is a remainder term. This is the Taylor expansion of f about a.

If we want to approximate this to first order, it just means that you use up to the $x - a$ term and scrap the rest, meaning that $f(x) \approx f(a) + f'(a)(x-a)$

Corner Detection: Mathematics

$$E(u,v) = \sum_{(x,y)\in W} [I(x+u, y+v) - I(x,y)]^2$$

$$\approx \sum_{(x,y)\in W} [I(x,y) + \begin{bmatrix} I_x & I_y \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} - I(x,y)]^2$$

$$= \sum_{(x,y)\in W} \left(\begin{bmatrix} I_x & I_y \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} \right)^2$$

$$= \sum_{(x,y)\in W} \begin{bmatrix} u & v \end{bmatrix} \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix}$$

Corner Detection: Mathematics

The quadratic approximation simplifies to

$$E(u,v) \approx \begin{bmatrix} u & v \end{bmatrix} M \begin{bmatrix} u \\ v \end{bmatrix}$$

where M is a *second moment matrix* computed from image derivatives:

$$M = \sum_{(x,y) \in W} \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

Interpreting the second moment matrix

- The surface $E(u,v)$ is locally approximated by a quadratic form. Let's try to understand its shape.
  - Specifically, in which directions does it have the smallest/greatest change?

$E(u, v)$

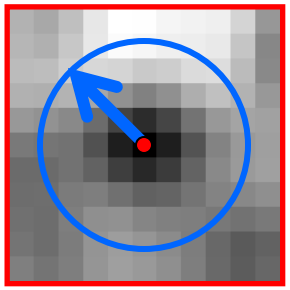

$$E(u,v) \approx \begin{bmatrix} u & v \end{bmatrix} M \begin{bmatrix} u \\ v \end{bmatrix}$$

$$M = \sum_{(x,y)\in W} \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

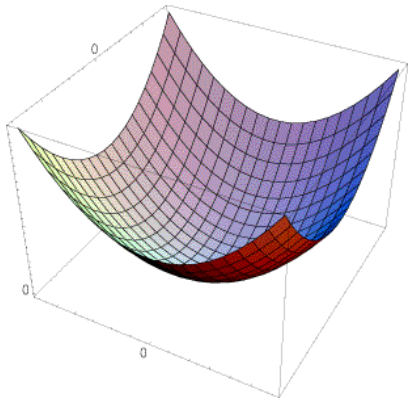

Interpreting the second moment matrix

First, consider the axis-aligned case (gradients are either horizontal or vertical)

$$M = \sum_{(x,y)\in W} \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} = \begin{bmatrix} a & 0 \\ 0 & b \end{bmatrix}$$

If either *a* or *b* is close to 0, then this is **not** a corner, so look for locations where both are large.

Interpreting the second moment matrix

Consider a horizontal "slice" of $E(u, v)$: $\begin{bmatrix} u & v \end{bmatrix} M \begin{bmatrix} u \\ v \end{bmatrix} = \text{const}$

This is the equation of an ellipse

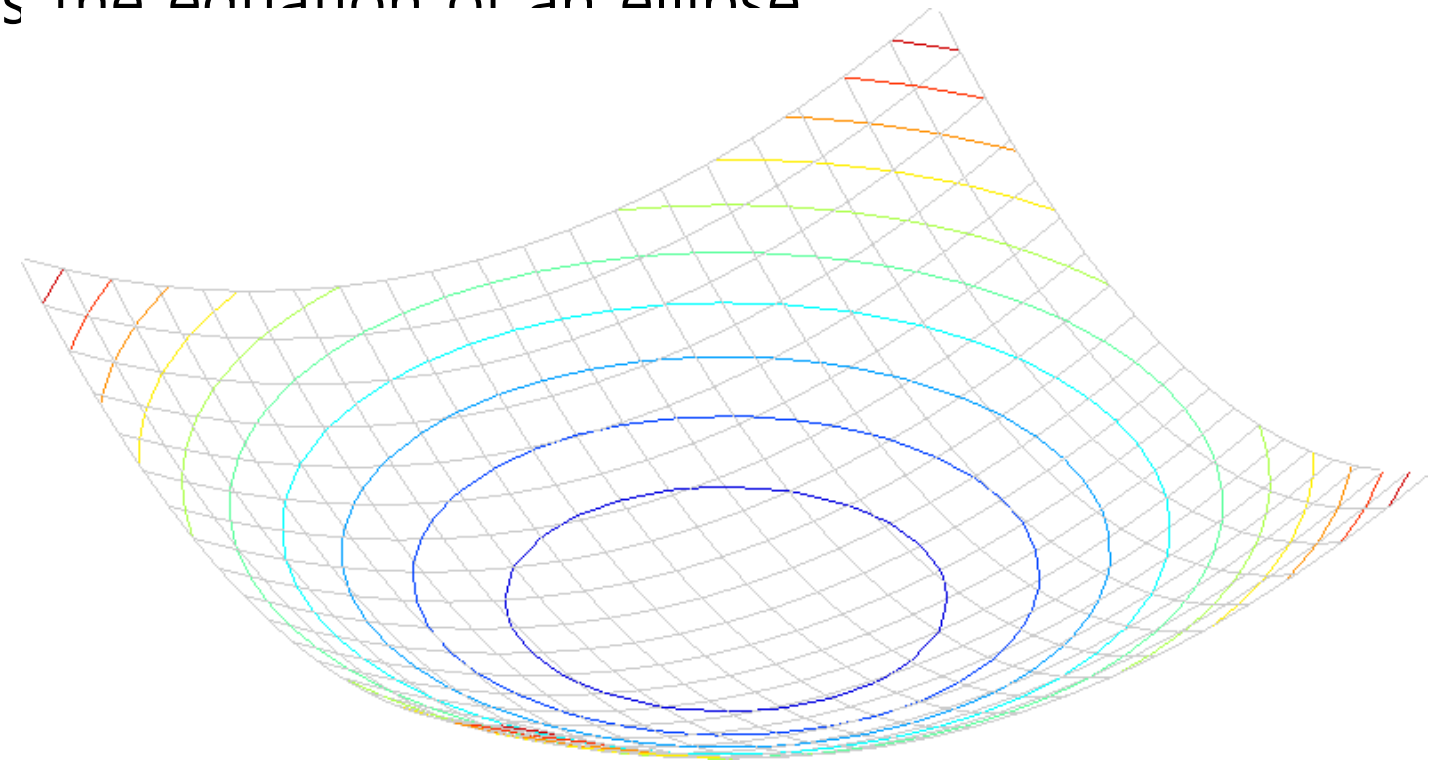

Interpreting the second moment matrix

Consider a horizontal "slice" of $E(u, v)$: $\begin{bmatrix} u & v \end{bmatrix} M \begin{bmatrix} u \\ v \end{bmatrix} = \text{const}$

This is the equation of an ellipse.

Diagonalization of M: $M = R^{-1} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} R$

Flat : $dx^2 \downarrow \; dy^2 \downarrow$

The axis lengths of the ellipse are determined by the eigenvalues and the orientation is determined by R

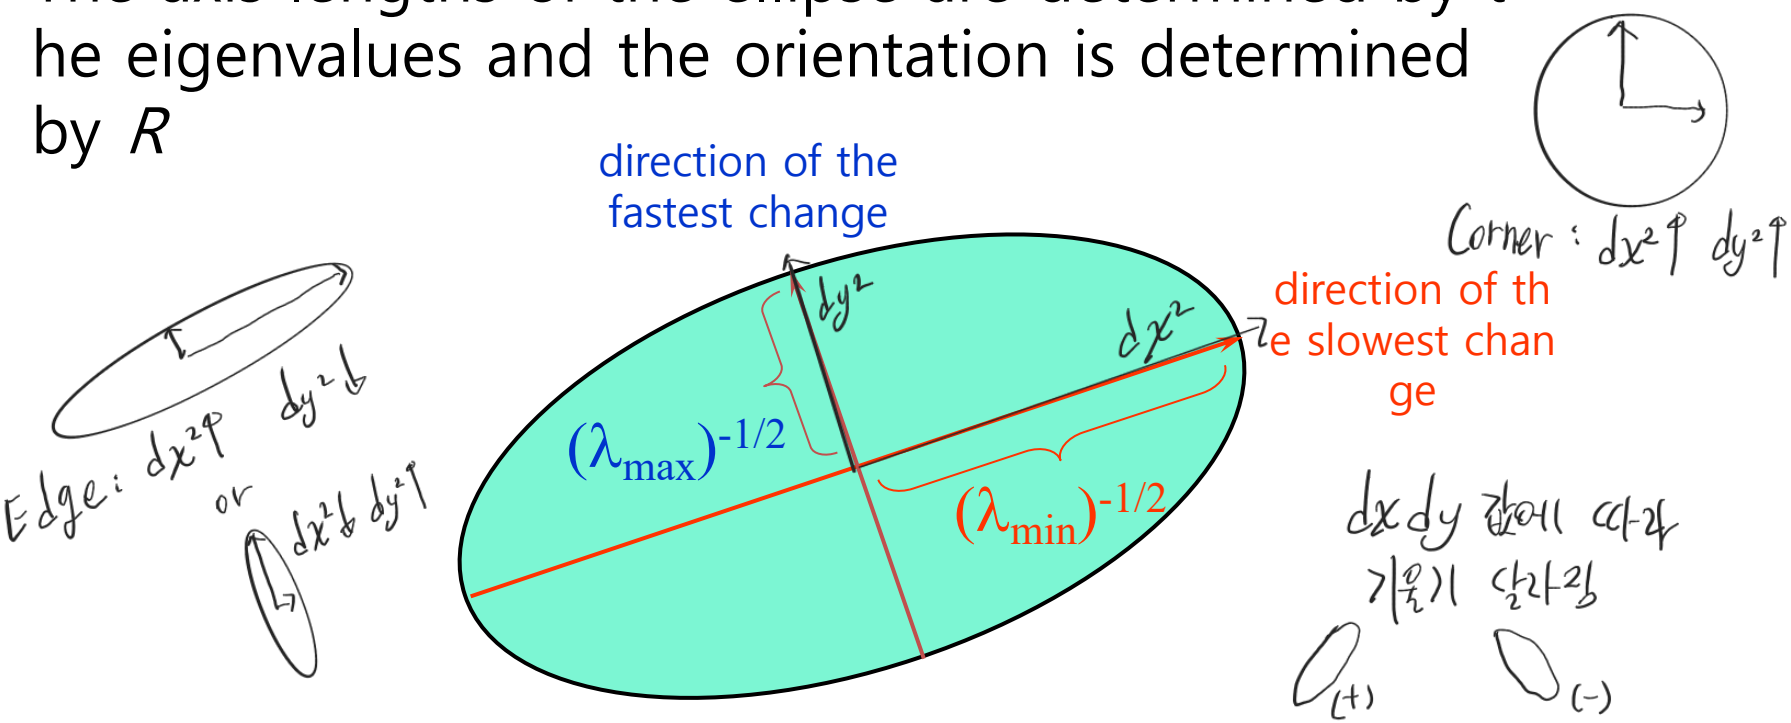

Interpreting the eigenvalues

Classification of image points using eigenvalues of M:

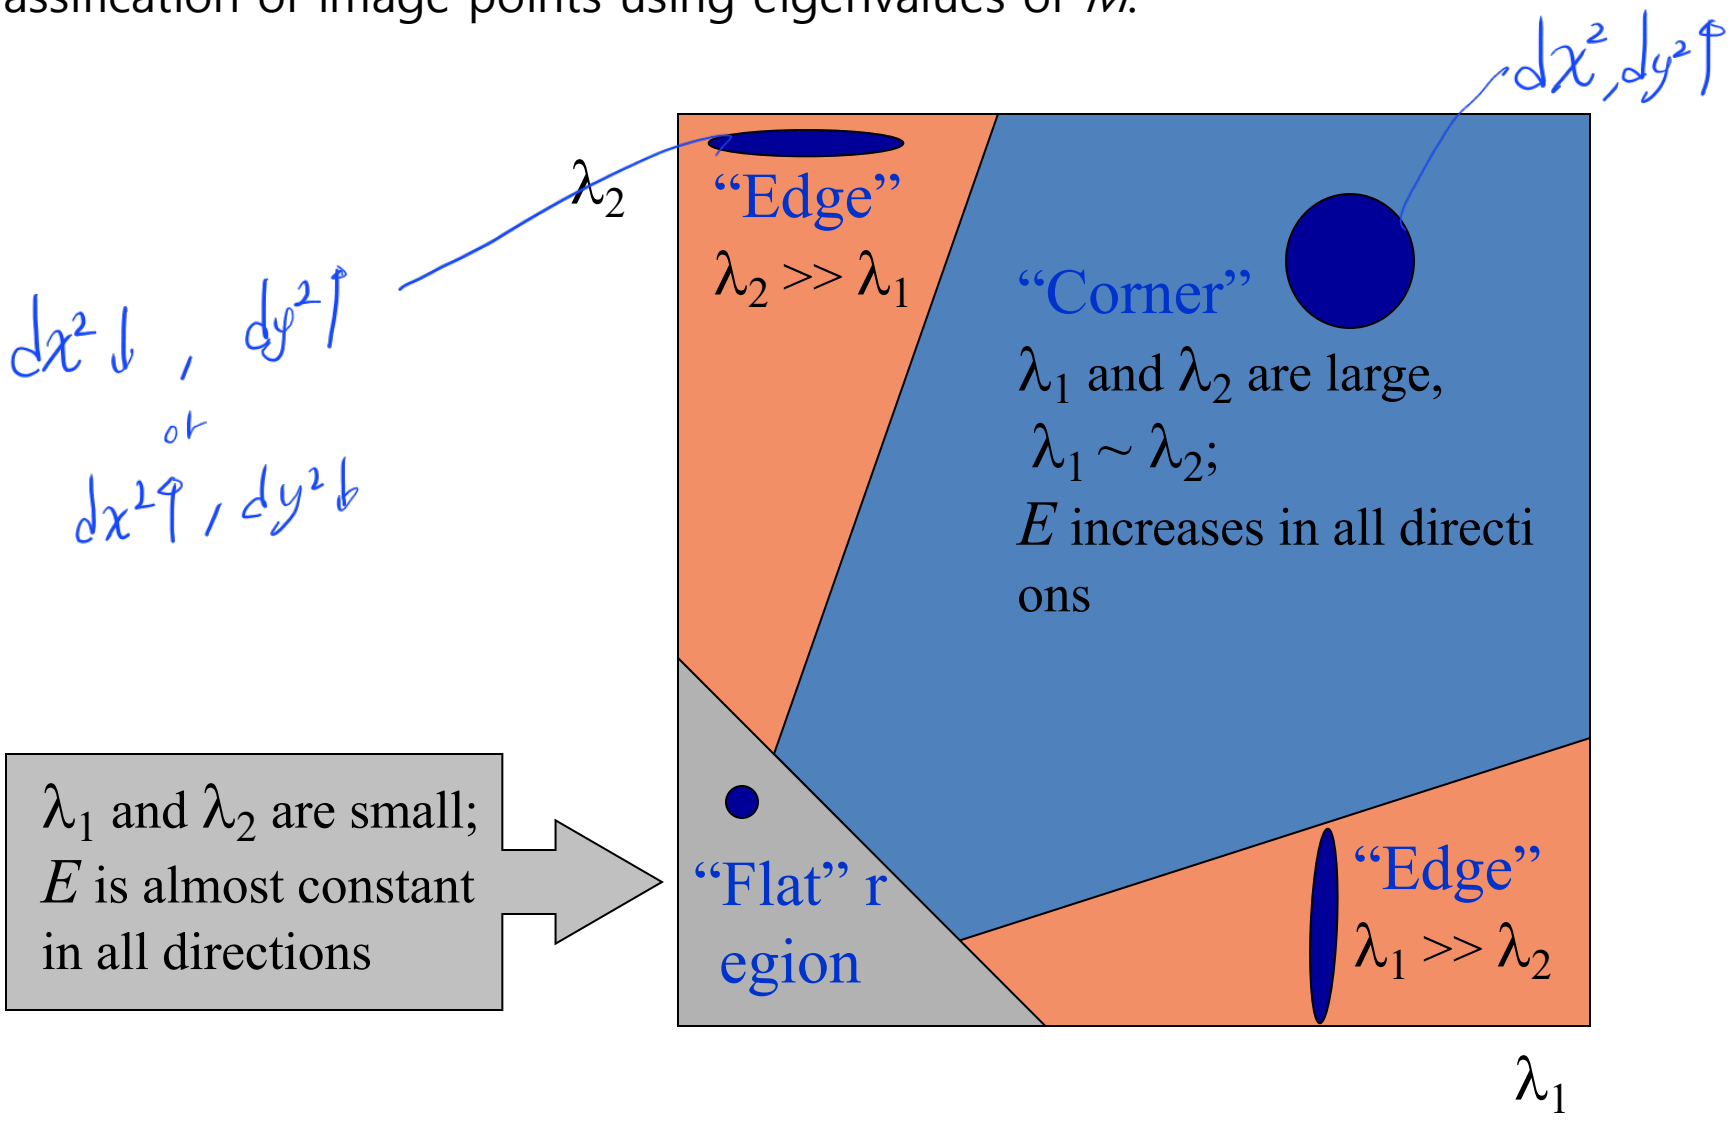

Corner response function

$$R = \det(M) - \alpha \,\text{trace}(M)^2 = \lambda_1\lambda_2 - \alpha(\lambda_1 + \lambda_2)^2$$

α: constant (0.04 to 0.06)

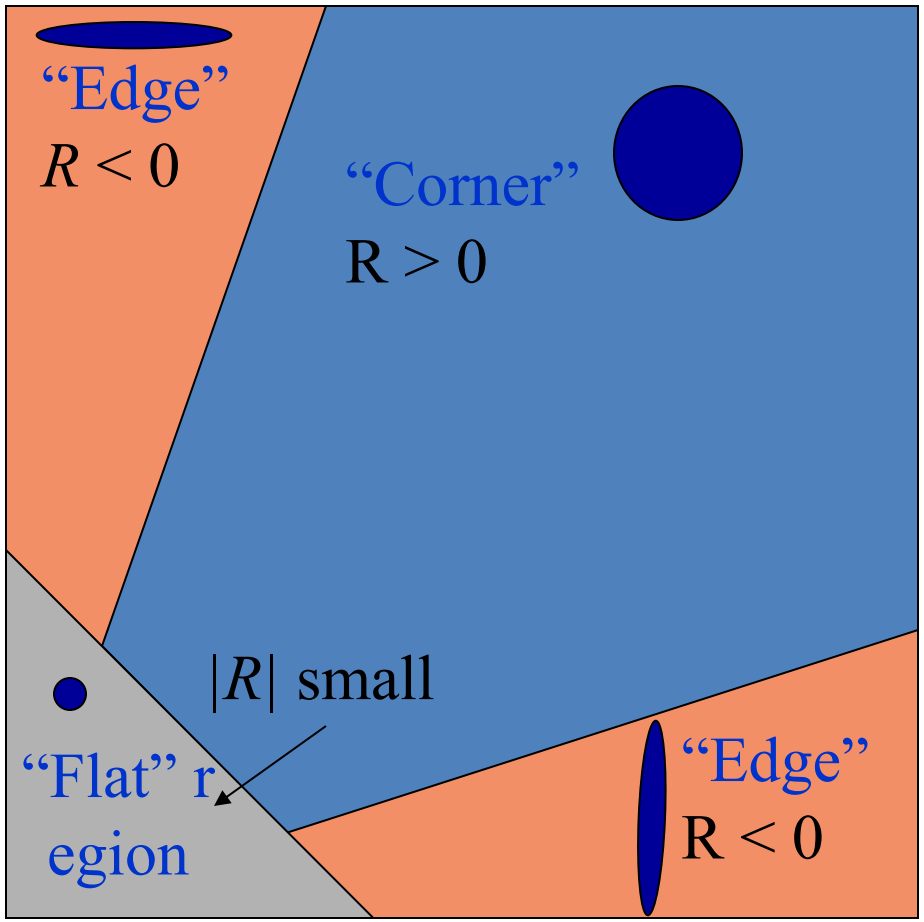

4.2.2 해리스 코너

예제 4-2 **2차 모멘트 행렬 A 계산**

[예제 4-1]에서 사용한 [그림 4-3(a)]의 영상에서 행렬 $\mathbf{A}$를 계산하는 과정을 살펴보자. [그림 4-5(a)]는 편의상 같은 영상을 다시 보여주는 것이고, [그림 4-5(b)]는 d_y, d_x, d_y^2, d_x^2, $d_y d_x$를 구한 영상이다. d_y와 d_x를 구하기 위해 각각 $[-1\ 0\ 1]^T$와 $[-1\ 0\ 1]$ 연산자를 사용하였다. [그림 4-5(c)~(e)]의 영상을 얻기 위해 다음과 같이 $\sigma=1.0$인 가우시안 마스크 G를 사용하였다.

$$G = \begin{array}{|c|c|c|}\hline .0751 & .1238 & .0751 \\ \hline .1238 & .2042 & .1238 \\ \hline .0751 & .1238 & .0751 \\ \hline \end{array}$$

이제 어떤 점의 행렬 $\mathbf{A}$를 구할 수 있다. 예를 들어, 점 a의 행렬은 $\mathbf{A} = \begin{pmatrix} 0.522 & -0.199 \\ -0.199 & 0.527 \end{pmatrix}$이다.

	0	1	2	3	4	5	6	7	8	9	10	11
0	0	0	0	0	0	0	0	0	0	0	0	0
1	0	0	0	0	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0	c 0	0	0	0
3	0	0	0	1	0	0	0	0	0	0	0	0
4	0	0	0	1	1	0	0	0	0	0	0	0
5	0	0	0	b 1	1	1	0	0	0	0	0	0
6	0	0	0	1	1	1	1	0	0	0	0	0
7	0	0	0	1	1	1	1	a 1	0	0	0	0
8	0	0	0	0	0	0	0	0	0	0	0	0
9	0	0	0	0	0	0	0	0	0	0	0	0
10	0	0	0	0	0	0	0	0	0	0	0	0
11	0	0	0	0	0	0	0	0	0	0	0	0

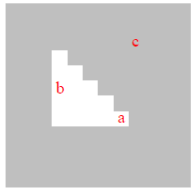

(a) 원래 영상 f

$> d_y$ $> d_x$ $> d_y^2$ $> d_x^2$ $> d_y d_x$

(b) 도함수 영상(흰색은 1, 회색은 0, 검은색은 −1)

4.2.2 해리스 코너

참고만

0	0	0	0	0	0	0	0	0	0	0	0
0	0	.075	.124	.075	0	0	0	0	0	0	0
0	0	.199	.403	.323	.075	0	0	0	0	0	0
0	0	.199	.527	.602	.323	.075	0	0	0	0	0
0	0	.075	.323	.602	.602	.323	.075	0	0	0	0
0	0	0	.075	.323	.602	.602	.323	.075	0	0	0
0	0	.075	.199	.349	.597	.726	.478	.124	0	0	0
0	0	.199	.527	.726	.801	.801	.522	.150	0	0	0
0	0	.199	.527	.726	.726	.651	.403	.124	0	0	0
0	0	.075	.199	.274	.274	.274	.199	.075	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0

(c) $G \circledast d_y^2$

0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0
0	.075	.124	.150	.124	.075	0	0	0	0	0	0
0	.199	.403	.521	.478	.323	.075	0	0	0	0	0
0	.274	.651	.801	.726	.602	.323	.075	0	0	0	0
0	.274	.726	.801	.597	.602	.602	.323	.075	0	0	0
0	.274	.726	.726	.349	.323	.602	.602	.323	.075	0	0
0	.199	.527	.527	.199	.075	.323	.527	.403	.124	0	0
0	.075	.199	.199	.075	0	.075	.199	.199	.075	0	0
0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0

(d) $G \circledast d_x^2$

0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	-.075	-.124	-.075	0	0	0	0	0	0
0	0	0	-.199	-.403	-.323	-.075	0	0	0	0	0
0	0	0	-.199	-.527	-.602	-.323	-.075	0	0	0	0
0	0	0	-.075	-.323	-.602	-.602	-.323	-.075	0	0	0
0	0	-.075	-.124	-.150	-.323	-.527	-.403	-.124	0	0	0
0	0	-.075	-.204	-.124	-.075	-.199	-.199	-.075	0	0	0
0	0	-.075	-.124	-.075	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0

(e) $G \circledast d_y d_x$

그림 4–5 2차 모멘트 행렬 **A**를 구하는 과정

4.2.2 해리스 코너

- 2차 모멘트 행렬의 고유값 분석
  - c와 같이 두 개의 고유값 모두 0이거나 0에 가까우면 → 변화가 거의 없는 곳
  - b와 같이 고유값 하나는 크고 다른 하나는 작으면 → 한 방향으로만 변화가 있는 에지
  - a와 같이 고유값 두 개가 모두 크면 → 여러 방향으로 변화가 있는 지점. 특징점으로 적합!

표 4-1 세 점에서의 특징 가능성 값

	a	b	c
2차 모멘트 행렬	$\mathbf{A}=\begin{pmatrix}0.522 & -0.199\\ -0.199 & 0.527\end{pmatrix}$	$\mathbf{A}=\begin{pmatrix}0.075 & -0.075\\ -0.075 & 0.801\end{pmatrix}$	$\mathbf{A}=\begin{pmatrix}0 & 0\\ 0 & 0\end{pmatrix}$
고유값	$\lambda_1=0.7235,\ \lambda_2=0.3255$	$\lambda_1=0.8087,\ \lambda_2=0.0673$	$\lambda_1=0.0,\ \lambda_2=0.0$
특징 가능성 값	$C=0.1925$	$C=0.0237$	$C=0.0$

4.2.2 해리스 코너

- 특징 가능성 값 측정

$$C = \lambda_1 \lambda_2 - k(\lambda_1 + \lambda_2)^2 \qquad (4.8)$$

  - 고유값 계산을 피해 속도 향상

$$\mathbf{A} = \begin{pmatrix} p & r \\ r & q \end{pmatrix}$$

$$C = det(\mathbf{A}) - k \times trace(\mathbf{A})^2 = (pq - r^2) - k(p+q)^2 \qquad (4.9)$$

특징이라는게 무엇인가
리얼특징이라는게 무엇인가

4.2.2 해리스 코너

그림 4-6 해리스 코너

← C>0.02인 점을 검출

- 위치 찾기 문제 대두
  - 큰 C 값을 가진 큰 점들이 밀집되어 나타나므로 대표점 선택 필요
- 코너라는 용어가 적절한가?
  - 코너 → 특징점 또는 관심점

Harris detector: Steps

1. Compute Gaussian derivatives at each pixel
2. Compute second moment matrix *M* in a Gaussian wind ow around each pixel
3. Compute corner response function *R*
4. Threshold *R*
5. Find local maxima of response function (nonmaximum suppression)

SIFT : scale 상관 없이 이용

C.Harris and M.Stephens. "A Combined Corner and Edge Detector." *Pro ceedings of the 4th Alvey Vision Conference*: pages 147—151, 1988.

조명 환경에서 완벽 X / 각각거나 입자-에 따라 달라짐 scale

Harris Detector: Steps

조명O / 조명X

Harris Detector: Steps

Compute corner response R

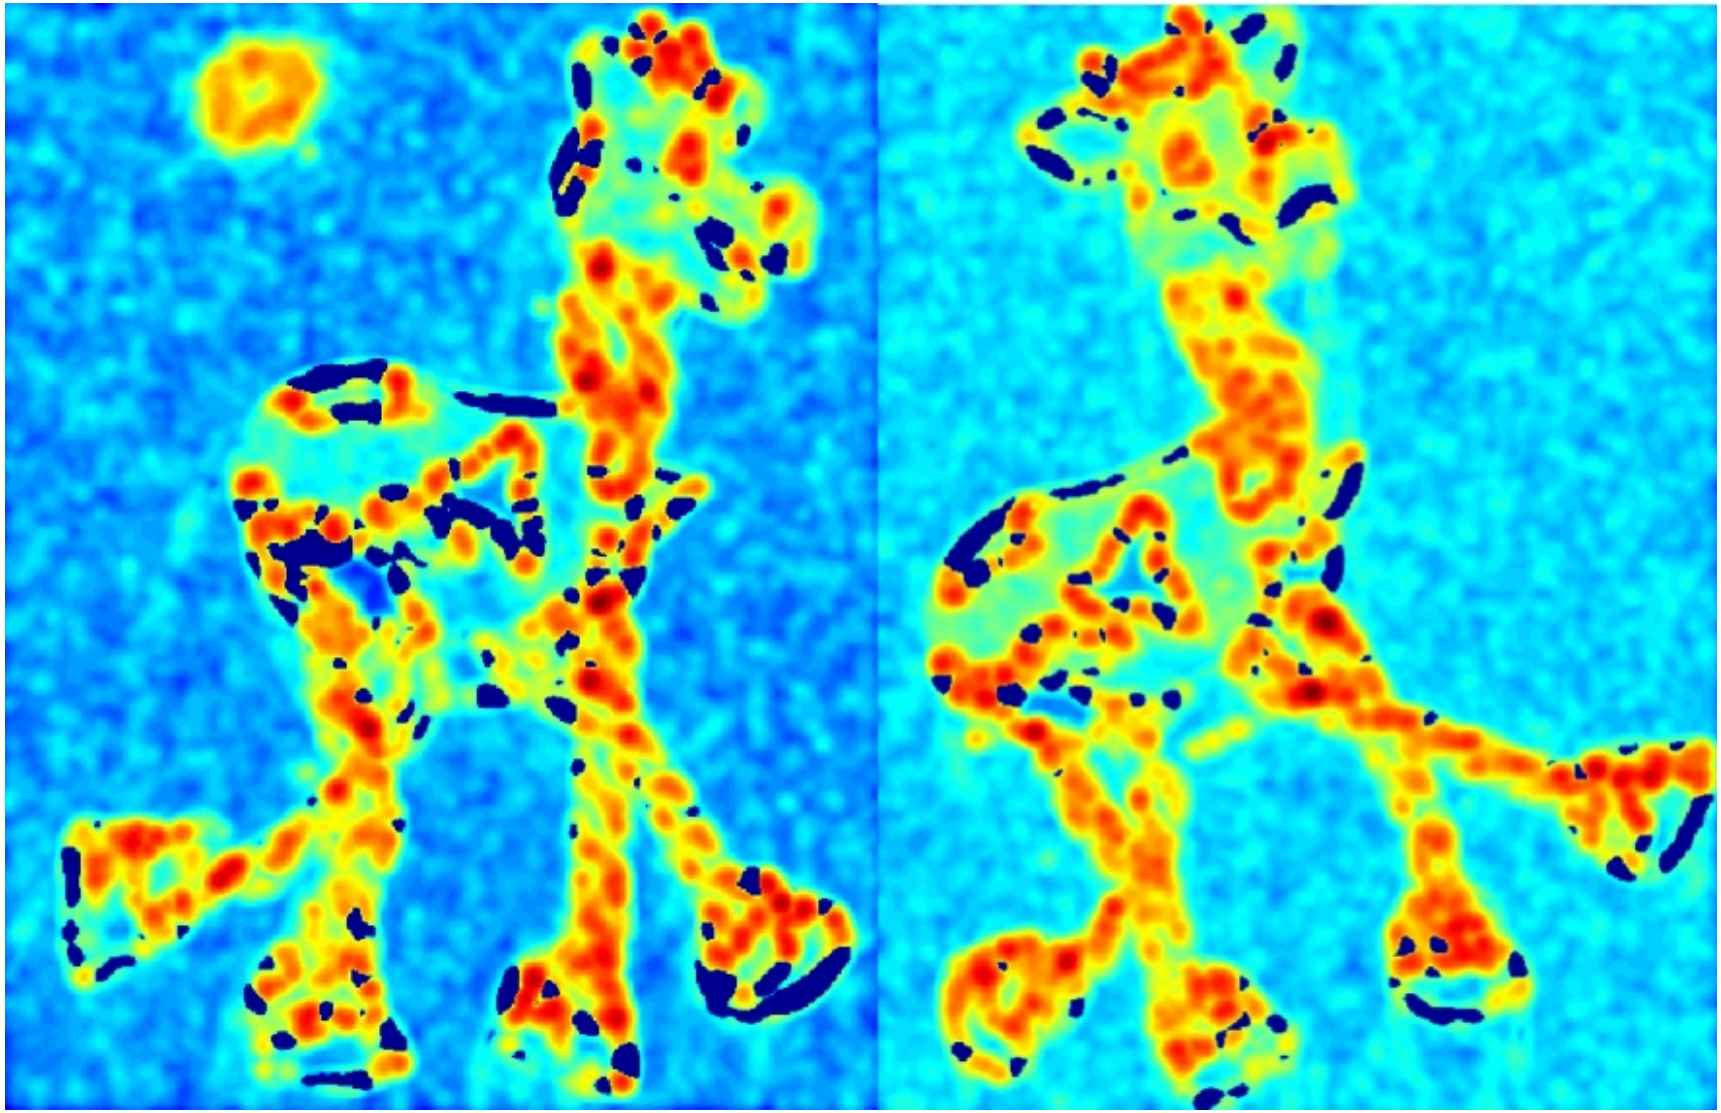

Harris Detector: Steps

Find points with large corner response: R>threshold

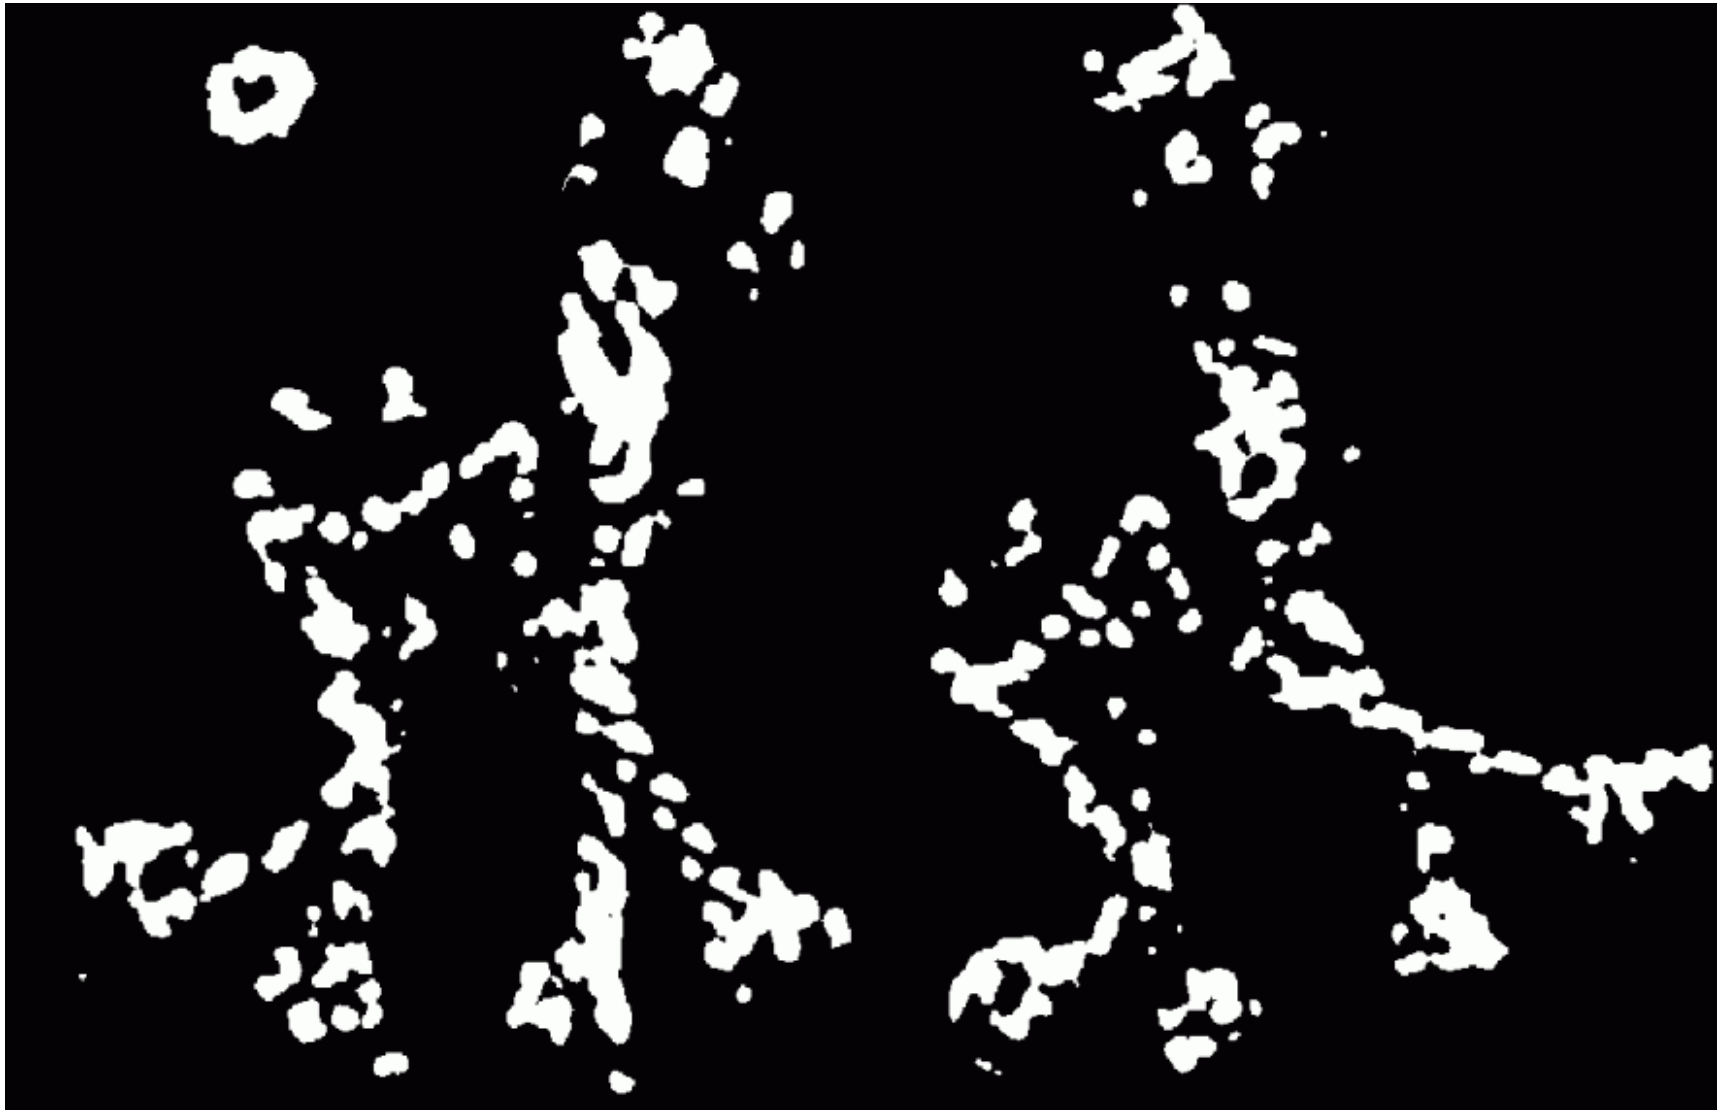

Harris Detector: Steps

Take only the points of local maxima of R

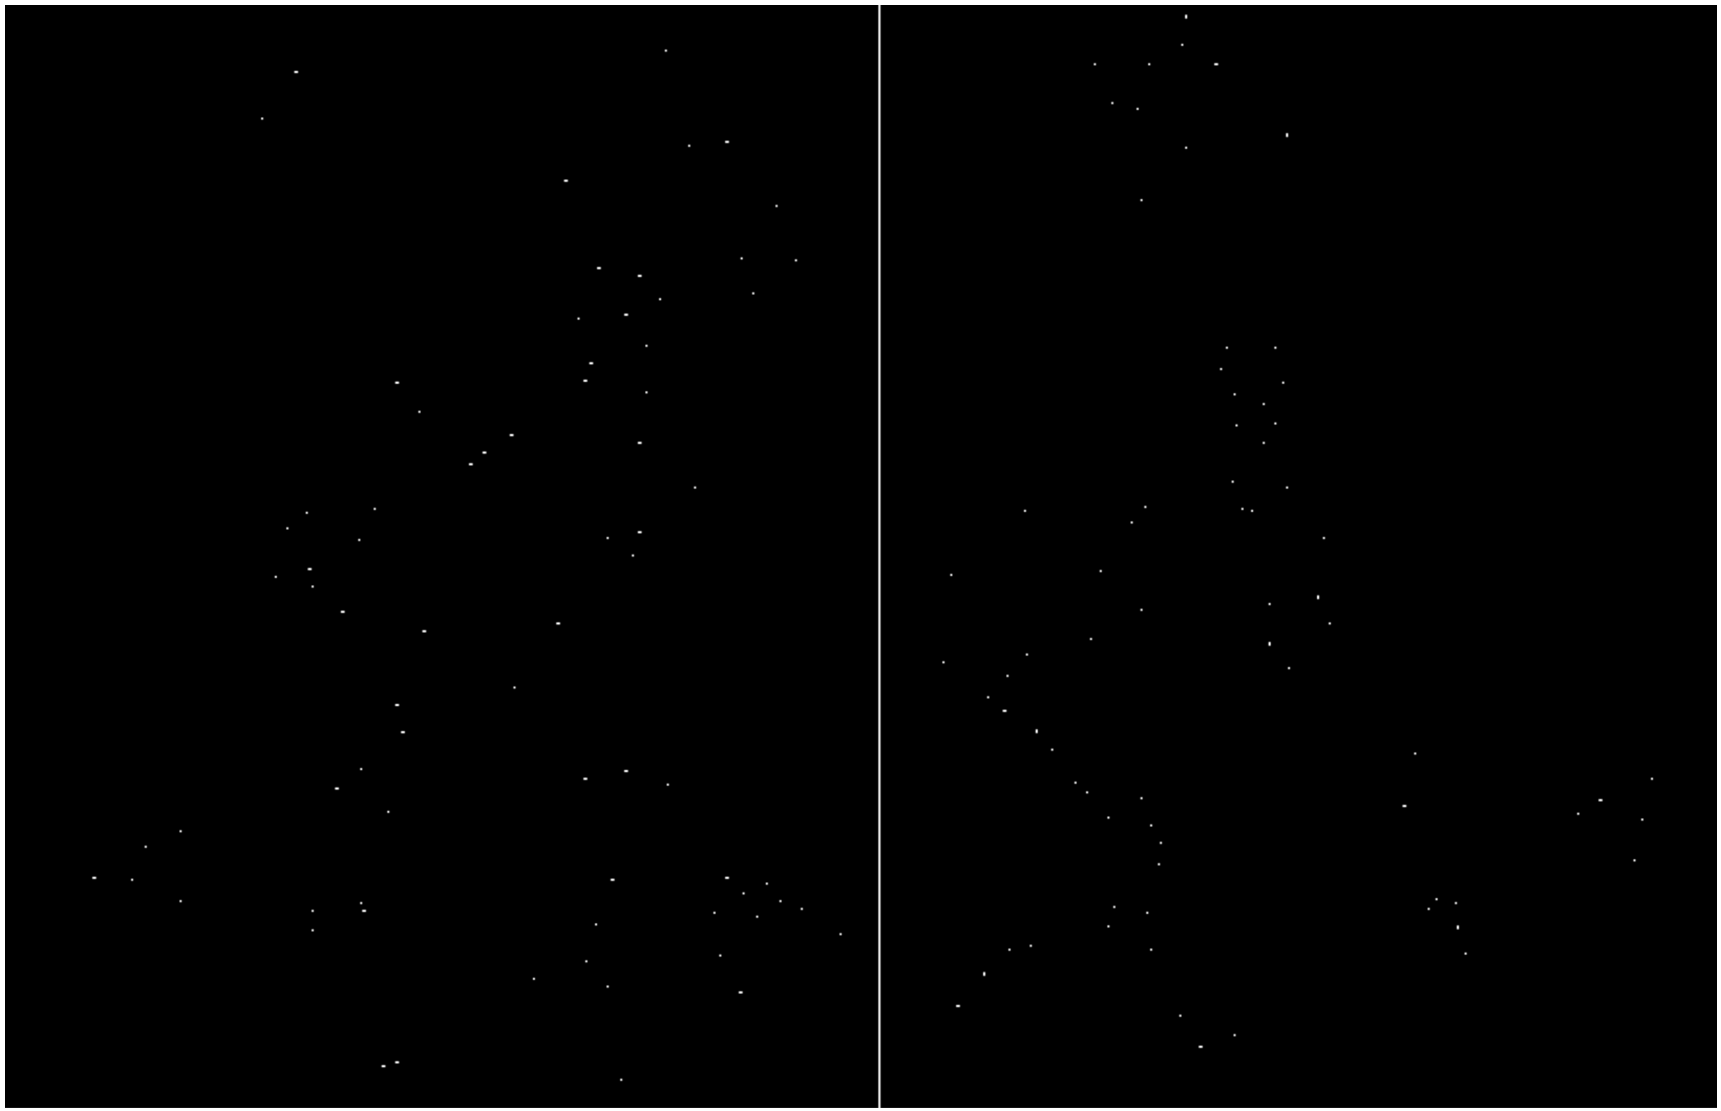

Harris Detector: Steps

Invariance and covariance

- We want corner locations to be *invariant* to photometric transformations and *covariant* to geometric transformations
  - **Invariance:** image is transformed and corner locations do not change
  - **Covariance:** if we have two transformed versions of the same image, features should be detected in corresponding locations

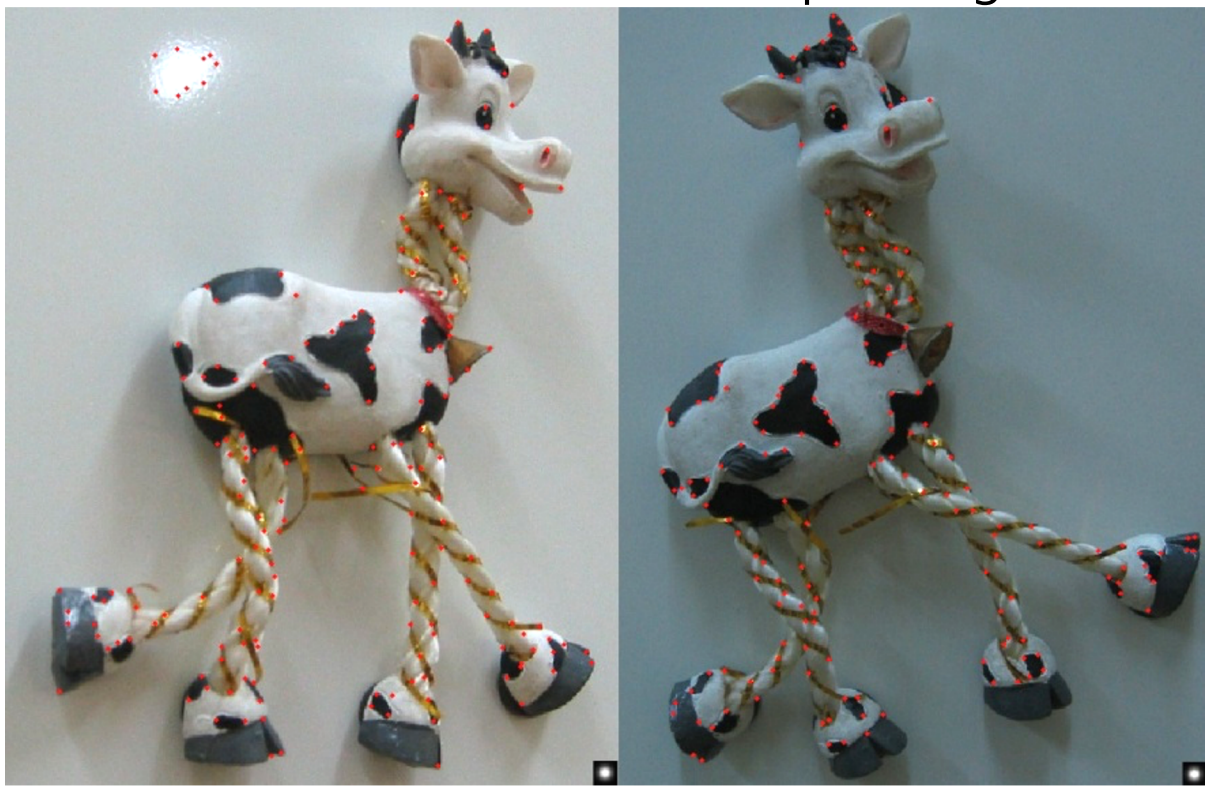

4.2.3 2차 미분을 사용한 방법

- 헤시안 행렬

$$\mathbf{H} = \begin{pmatrix} d_{yy} & d_{yx} \\ d_{yx} & d_{xx} \end{pmatrix}$$

  - 가우시안을 포함한 헤시안 행렬

$$\mathbf{H} = \begin{pmatrix} d_{yy}(\sigma) & d_{yx}(\sigma) \\ d_{yx}(\sigma) & d_{xx}(\sigma) \end{pmatrix} \tag{4.11}$$

이때 $d_{st}(\sigma) = \frac{\partial}{\partial t}\left(\frac{\partial}{\partial s}(G(y,x,\sigma) \circledast f(y,x))\right)$, s와 t는 y 또는 x

- 2차 미분에서 특징 가능성 값 측정

• 헤시안의 행렬식determinant

$$C = det(\mathbf{H}) = d_{yy}(\sigma)\,d_{xx}(\sigma) - d_{yx}(\sigma)^2 \tag{4.12}$$

• 가우시안 라플라시안(LOG)

$$C = \nabla^2 = trace(\mathbf{H}) = d_{yy}(\sigma) + d_{xx}(\sigma) \tag{4.13}$$

4.2.4 슈산

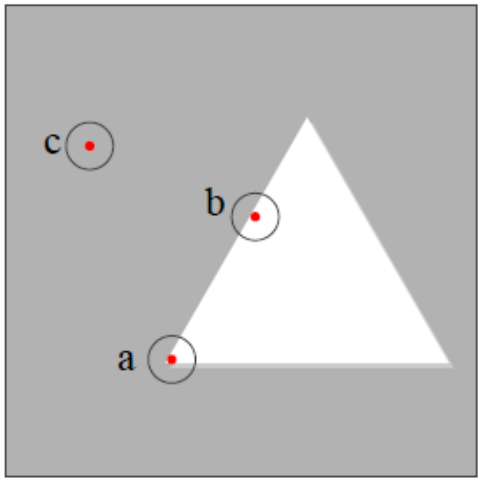

그림 4-7 슈산의 원리

		1	1	1		
	1	1	1	1	1	
1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1
	1	1	1	1	1	
		1	1	1		

그림 4-8 슈산이 사용하는 7×7 크기의 원형 마스크(넓이는 37)

원리

- 중심점과 인근 지역의 밝기 값이 얼마나 유사한지에 따라 특징 가능성 결정

$$usan_area(r_0) = \sum_r s(r, r_0)$$

$$\text{이때 } s(r, r_0) = \begin{cases} 1, & |f(r) - f(r_0)| \le t_1 \\ 0, & \text{그렇지 않으면} \end{cases} \tag{4.14}$$

$$C = \begin{cases} q - usan_area(r_0), & usan_area(r_0) \le t_2 \\ 0, & \text{그렇지 않으면} \end{cases} \tag{4.15}$$

4.3 위치 찾기 알고리즘

- 지금까지 공부한 여러 가지 특징 가능성 측정 방법
  - 모라벡 $$C = \min(S(0,1), S(0,-1), S(1,0), S(-1,0)) \quad (4.2)$$
  - 해리스 $$C = det(\mathbf{A}) - k \times trace(\mathbf{A})^2 = (pq - r^2) - k(p+q)^2 \quad (4.9)$$
  - 헤시안의 행렬식 $$C = det(\mathbf{H}) = d_{yy}(\sigma) d_{xx}(\sigma) - d_{yx}(\sigma)^2 \quad (4.12)$$
  - LOG $$C = \nabla^2 = trace(\mathbf{H}) = d_{yy}(\sigma) + d_{xx}(\sigma) \quad (4.13)$$
  - 슈산 $$C = \begin{cases} q - usan_area(r_0), & usan_area(r_0) \le t_2 \\ 0, & \text{그렇지 않으면} \end{cases} \quad (4.15)$$

4.3 위치 찾기 알고리즘

- 해리스 적용 예
  - 큰 값이 밀집되어 나타남 → 대표점 선택 필요

0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	-.001	0	0	0	0	0	0	0	0
0	0	.021	.043	.017	-.001	0	0	0	0	0	0
0	-.002	.066	**.191**	.079	-.017	-.001	0	0	0	0	0
0	-.003	.028	.169	.089	-.058	-.017	-.001	0	0	0	0
0	-.003	-.021	.024	.055	-.058	-.058	-.017	-.001	0	0	0
0	-.003	.023	.095	.080	.055	.089	.079	.017	0	0	0
0	-.002	.068	**.192**	.095	.024	.169	**.191**	.043	-.001	0	0
0	0	.028	.068	.023	-.021	.028	.066	.021	0	0	0
0	0	0	-.002	-.003	-.003	-.003	-.002	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0

(a) 식 (4.9)로 계산한 특징 가능성 맵(굵게 표시된 부분은 지역 최대점)

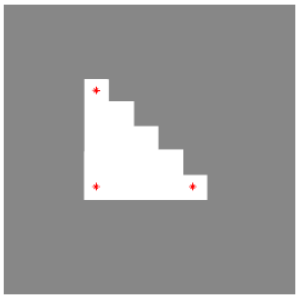

(b) 비최대 억제로 찾은 특징점

그림 4-9 특징 가능성 맵과 특징점 검출

4.3 위치 찾기 알고리즘

비최대 억제

- 이웃 화소보다 크지 않으면 억제됨 ⇒ 즉, 지역 최대만 특징점으로 검출됨

알고리즘 4-1 지역 특징 검출

입력 : 영상 $f(j,i)$, $0 \le j \le M-1$, $0 \le i \le N-1$, 임계값 T

출력 : 특징점 리스트 F

```
1   for(j=0 to N-1)  // 1~3행 : 특징 가능성 맵 생성
2     for(i=0 to M-1)
3       (j,i)의 특징 가능성 값 C를 계산하여 m(j,i)에 대입한다.
4   F=Ø;  // 공집합으로 시작
5   for(j=1 to N-2)
6     for(i=1 to M-2) {
7       c=m(j,i);
8       if((c>T) and (c>m(j,i+1) and c>m(j,i-1) and c>m(j+1,i) and c>m(j-1,i)))// 4-이웃 버전
9         F= F∪(j,i);  // 점 (j,i)를 특징점으로 판정하고 F에 추가함
10    }
```

4.3 위치 찾기 알고리즘

- 이동과 회전에 불변인가?
  - 이동이나 회전 변환이 발생하여도 같은 지점에서 관심점이 검출되나?

    ⇒ yes! 검출된다.

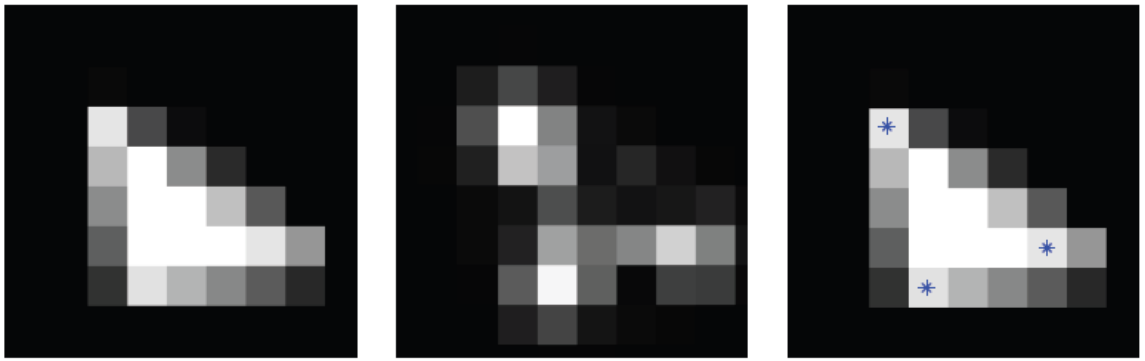

(a) 회전한 영상 (b) 가능성 맵 (c) 관심점 검출

그림 4–10 회전한 삼각형에서 관심점 검출

4.3 위치 찾기 알고리즘

- 스케일에 불변인가?
  - 스케일이 변해도 같은 지점에서 관심점이 검출되나?

    ⇒ 연산자 크기가 고정되어 있어 그렇지 않다.
    스케일 변화에 대처하려면 연산자 크기를 조절하는 기능이 필수적임

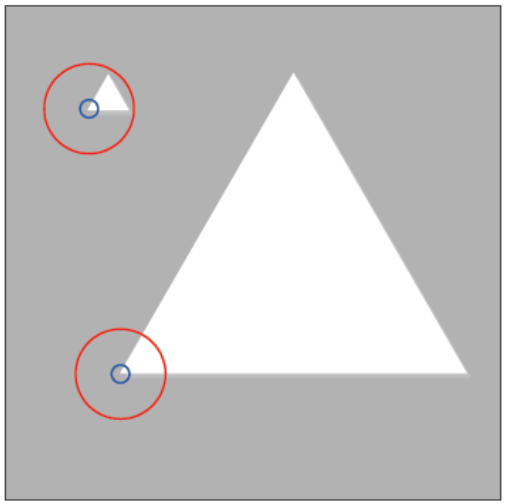

그림 4-11 스케일에 따른 적절한 연산자 크기